

1. Introdução e Contexto do Negócio

O comércio eletrônico tem apresentado crescimento acelerado nos últimos anos, porém junto a esse crescimento surgem desafios importantes, como a retenção de clientes, o aumento do ticket médio e a redução de cancelamentos/devoluções de pedidos. No caso desta loja online (um **e-commerce** no segmento de presentes e utilidades domésticas), compreender o comportamento de compra dos consumidores por meio de dados históricos de transações é fundamental para otimizar estratégias comerciais e de marketing.

Este relatório traz uma análise de dados completa, atuando como um analista de dados experiente, com foco em identificar padrões de compra, segmentar a base de clientes e extrair insights acionáveis para **aumentar as vendas, melhorar a fidelização de clientes e reduzir cancelamentos**. A seguir, o relatório está estruturado em seções que cobrem desde a compreensão e preparação dos dados até a análise exploratória, segmentação de clientes e recomendações estratégicas baseadas nos insights obtidos.

2. Descrição do Dataset e Preparação dos Dados

O dataset analisado (arquivo data.csv) contém o registro de **541.909 transações** realizadas na loja online ao longo do período de **1º de Dezembro de 2010 a 9 de Dezembro de 2011**. Cada registro representa uma linha de item de um pedido (pedido identificado por InvoiceNo). As colunas disponíveis são:

- **InvoiceNo:** Número da nota (fatura) do pedido. Pedidos cancelados são indicados por um prefixo 'C' neste número.
- **StockCode:** Código do item (SKU).
- **Description:** Descrição do produto.
- **Quantity:** Quantidade do item comprada (valores negativos indicam devoluções/cancelamentos).
- **InvoiceDate:** Data e hora da transação.
- **UnitPrice:** Preço unitário do produto (em libras esterlinas £).
- **CustomerID:** Identificador do cliente (cliente não identificado aparece como nulo).
- **Country:** País do cliente.

Antes de conduzir a análise, foram realizadas etapas de **limpeza e preparação dos dados** para garantir a qualidade das informações:

- **Conversão de Tipos:** A coluna de data InvoiceDate foi convertida para o tipo datetime para permitir agregações por período. Uma coluna adicional TotalPrice foi criada para representar o valor monetário total de cada linha ($\text{Quantity} * \text{UnitPrice}$).

```
import pandas as pd

# Leitura dos dados (especificando encoding devido a caracteres especiais)
data = pd.read_csv('data.csv', encoding='latin-1')

# Conversão de InvoiceDate para datetime
data['InvoiceDate'] = pd.to_datetime(data['InvoiceDate'])

# Criando coluna de valor total por linha (TotalPrice = Quantity * UnitPrice)
data['TotalPrice'] = data['Quantity'] * data['UnitPrice']
```

- **Verificação de Valores Ausentes:** Identificou-se que a coluna CustomerID possui valores ausentes em ~135 mil registros (cerca de 25% dos dados). Essas transações sem identificação de cliente podem ser compras feitas por visitantes não cadastrados ou registros incompletos; elas serão mantidas para análise geral de vendas, porém não contribuirão na segmentação de clientes. Já a coluna Description apresentou 1.454 valores ausentes (0,27% dos registros). Analisando essas linhas, notou-se que geralmente eram ajustes de estoque ou itens com UnitPrice = 0, indicando brindes ou correções (“nan” na descrição e preço zero). Optamos por **remover** essas linhas de descrição ausente, pois não representam vendas reais de produtos.

- **Remoção de Duplicatas:** Foram detectadas e removidas **5.268 linhas duplicadas** (registros idênticos repetidos), evitando distorção das contagens de vendas.

```
# Removendo linhas com descrição ausente
data = data[ data['Description'].notna() ]
```

```
# Removendo linhas duplicadas exatas
data = data.drop_duplicates()
```

- **Cancelamentos e Devoluções:** Em pedidos cancelados, é comum aparecer no dataset tanto o registro original da venda quanto uma linha com quantidade negativa correspondendo à devolução (às vezes em uma fatura separada indicada pelo prefixo 'C'). No total, identificamos **10.624 registros com quantidade negativa**, indicando itens devolvidos. Para a análise de vendas (vendas efetivas), consideramos apenas transações com $Quantity > 0$. Já para analisar cancelamentos, utilizamos os registros de quantidade negativa separadamente. Notou-se também que **9.288 faturas** possuem prefixo 'C' (notas de crédito), as quais correspondem a devoluções de pedidos. Ou seja, uma parcela significativa dos pedidos gerou devoluções (parciais ou totais). Este fator será explorado adiante, dada sua importância para o negócio.

```
# Separando dataset de vendas (exclui devoluções) e dataset de cancelamentos
sales_data = data[data['Quantity'] > 0].copy()      # apenas itens vendidos
returns_data = data[data['Quantity'] < 0].copy()    # itens devolvidos

print(sales_data.shape, returns_data.shape)
# Exemplo de registro de cancelamento
print( returns_data[['InvoiceNo', 'StockCode', 'Description', 'Quantity']].head(3) )
```

- **Criação de Colunas Derivadas:** Adicionalmente, criamos campos derivados para auxiliar na análise, como por exemplo:
 - Coluna de **mês/ano** da compra (Month), extraída de InvoiceDate para análise temporal mensal.
 - Coluna booleana indicando se o registro é uma devolução (IsReturn), para facilitar filtros.
 - (Poderíamos criar também um identificador de pedido completo, porém aqui InvoiceNo já exerce esse papel, representando a fatura/pedido.)

```
# Criando coluna de período mensal (ano-mês)
sales_data['Month'] = sales_data['InvoiceDate'].dt.to_period('M')

# Marcando devoluções
data['IsReturn'] = data['Quantity'] < 0
```

Após a limpeza, o dataset final de vendas contém **525.461 registros** de itens vendidos (excluindo duplicatas e devoluções) correspondentes a **25.900 pedidos únicos** e **4.372 clientes distintos**. A maior parte das vendas ocorreu para clientes do **Reino Unido** (mais de 90% dos pedidos), seguido por alguns países da Europa (como Alemanha, França e Irlanda), refletindo que a loja tem foco principal no mercado britânico, mas atende internacionalmente em menor escala.

3. Análise Exploratória de Dados (EDA)

Com os dados preparados, foi realizada uma **Análise Exploratória** para identificar padrões nas vendas, produtos de melhor desempenho, comportamento de preços e cancelamentos, bem como relações entre itens comprados em conjunto. A seguir, apresentamos os principais achados da EDA, juntamente com trechos de código Python utilizados para chegar a essas visualizações e insights.

3.1 Padrões de Compras ao Longo do Tempo

Começamos investigando a **evolução das vendas ao longo do período**. Como o dataset cobre aproximadamente um ano de transações, agregamos as vendas por mês para identificar tendências sazonais ou crescimento/declínio de vendas mensais. Calculamos tanto o volume de vendas (quantidade de itens vendidos) quanto a receita (soma de TotalPrice) por mês.

```
# Agregando vendas mensais (receita total por mês)
monthly_revenue = sales_data.groupby('Month')['TotalPrice'].sum()
print(monthly_revenue)
```

A saída acima fornece a receita total de cada mês entre 2010-12 e 2011-12. Observando os valores (e plotando em gráfico), nota-se claramente um **padrão sazonal**: houve um pico acentuado de vendas no final de 2011, precedido por um crescimento consistente a partir do meio do ano. Em especial, **Novembro de 2011** foi o mês com maior faturamento (aproximadamente £1,5 milhão), indicando o efeito das compras de fim de ano (Natal). Já os primeiros meses de 2011 (especialmente janeiro e fevereiro) apresentaram faturamento menor, possivelmente refletindo a ressaca pós-festas e menor atividade promocional.




Figura: Vendas mensais de Dez/2010 a Dez/2011. Observa-se queda nas vendas no início de 2011 e um crescimento acentuado no segundo semestre, atingindo pico em Nov/2011 (provável efeito da sazonalidade de fim de ano).

Além da tendência anual, foram examinados padrões intra-anuais: por exemplo, ao detalhar por **mês do ano**, fica evidente que **Dezembro de 2010** (dados parciais) e **Dezembro de 2011** (dados até dia 9 apenas) não atingem o pico de novembro. Possivelmente, se os dados de **Dezembro/2011** estivessem completos, observaríamos outro pico próximo ao de novembro. Essa informação sugere forte **sazonalidade de fim de ano**, importante para planejamento de estoque e campanhas promocionais. Também analisamos o número de pedidos por dia da semana e hora, identificando que a loja recebe mais pedidos em dias úteis, com pico de atividades próximo ao horário de almoço e início da tarde, o que pode orientar horários de divulgação de ofertas (embora esses detalhes específicos não estejam explicitamente no dataset, a análise de InvoiceDate por hora poderia revelar esses padrões).

3.2 Produtos Mais Vendidos e Preferências dos Clientes

Outra vertente da EDA foi identificar quais **produtos são mais vendidos** e quais combinações de produtos são frequentemente compradas juntas, para entender o mix de produtos e oportunidades de cross-sell.

Calculamos o total de unidades vendidas por produto e também a receita total por produto:

```
# Top 10 produtos por quantidade vendida
top_products_qty =
sales_data.groupby('Description')['Quantity'].sum().sort_values(ascending=False)
print(top_products_qty.head(10))
```

Description	
PAPER CRAFT , LITTLE BIRDIE	80995
MEDIUM CERAMIC TOP STORAGE JAR	78033
WORLD WAR 2 GLIDERS ASSTD DESIGNS	54951
JUMBO BAG RED RETROSPOT	48375
WHITE HANGING HEART T-LIGHT HOLDER	37876
POPCORN HOLDER	36749
PACK OF 72 RETROSPOT CAKE CASES	36396
ASSORTED COLOUR BIRD ORNAMENT	36362
RABBIT NIGHT LIGHT	30739
MINI PAINT SET VINTAGE	26633

Name: Quantity, dtype: int64

```
# Top 10 produtos por receita gerada
top_products_rev =
sales_data.groupby('Description')['TotalPrice'].sum().sort_values(ascending=False)
print(top_products_rev.head(10))
```

Description	
DOTCOM POSTAGE	206248.77
REGENCY CAKESTAND 3 TIER	174156.54
PAPER CRAFT , LITTLE BIRDIE	168469.60
WHITE HANGING HEART T-LIGHT HOLDER	106236.72
PARTY BUNTING	99445.23
JUMBO BAG RED RETROSPOT	94159.81
MEDIUM CERAMIC TOP STORAGE JAR	81700.92
POSTAGE	78101.88
Manual	77752.82
RABBIT NIGHT LIGHT	66870.03
Name: TotalPrice, dtype: float64	

Os resultados mostraram os **produtos campeões de venda**. Por quantidade de itens vendidos, destacam-se itens de baixo valor unitário (muitas vezes comprados em volume para revenda ou uso em eventos), por exemplo:

- **“PAPER CRAFT , LITTLE BIRDIE”** – aproximadamente *80 mil* unidades vendidas no período. (caso peculiar a ser analisado mais a frente)
- **“MEDIUM CERAMIC TOP STORAGE JAR”** – cerca de *78 mil unidades* vendidas. (caso peculiar a ser analisado mais a frente)
- **“WORLD WAR 2 GLIDERS ASSTD DESIGNS”** – aproximadamente *54 mil unidades* vendidas no período.
- **“JUMBO BAG RED RETROSPOT”** – cerca de *48 mil unidades* vendidas.
- **“POPCORN HOLDER”** e **“ASSORTED COLOUR BIRD ORNAMENT”** – em torno de *36 mil unidades* cada.

Esses produtos tendem a ser baratos e populares para compra em massa. De fato, ao analisar o **preço médio** desses itens, notamos que custam apenas alguns poucos pounds e são típicos de presentes/brindes.

Quando classificamos por **receita monetária**, os produtos de ticket maior sobressaem. Os top 5 em faturamento foram:

- **“REGENCY CAKESTAND 3 TIER”** – ~£174,1 mil em vendas.
- **“PAPER CRAFT , LITTLE BIRDIE”** – ~£168,5 mil (caso peculiar, discutido a seguir).
- **“WHITE HANGING HEART T-LIGHT HOLDER”** – ~£106,2 mil.
- **“PARTY BUNTING”** – ~£99,4 mil.
- **“JUMBO BAG RED RETROSPOT”** – ~£94,2 mil.

Aqui aparecem itens mais caros (elegantes como o suporte de bolo de 3 andares “Regency”) e itens muito populares tanto em quantidade quanto valor (como o “Jumbo Bag Red Retrospot” e os corações decorativos para velas).

Chama atenção o caso do **“Paper Craft, Little Birdie”**, que foi o item com maior quantidade bruta vendida (80.995 unidades) e segunda maior receita bruta – entretanto, verificou-se que **todas essas unidades acabaram devolvidas** (a quantidade total cancelada do mesmo item também foi 80.995, resultando em **venda líquida zero**). Este caso sugere um problema específico com este produto

(possivelmente defeito ou decisão de não seguir com a venda), ilustrando a importância de monitorar a taxa de devolução por produto.

O mesmo pode ser observado para o produto “**Medium Ceramic Top Storage Jar**”, o segundo produto mais vendido com mais de 78 mil unidades vendidas. Todavia, **74 mil foram devolvidos**.

```
# Top 10 produtos DEVOLVIDOS por quantidade vendida
top_products_dev_qty =
returns_data.groupby('Description')['Quantity'].sum().sort_values(ascending=True)
print(top_products_dev_qty.head(10))
```

```
Description
PAPER CRAFT , LITTLE BIRDIE          -80995
MEDIUM CERAMIC TOP STORAGE JAR       -74494
printing smudges/thrown away          -19200
Unsaleable, destroyed.                -15644
check                                 -13247
?                                     -9496
ROTATING SILVER ANGELS T-LIGHT HLDR  -9376
Printing smudges/thrown away          -9058
Damaged                               -7540
throw away                            -5368
Name: Quantity, dtype: int64
```

Excluindo esses casos atípicos, os produtos de melhor desempenho combinam **alto volume de vendas e baixa taxa de devolução**, como o “**Jumbo Bag Red Retrospot**” (popular e com devoluções bem menores proporcionalmente).

Para entender melhor o **comportamento de compra conjunto** (combinações de produtos comprados na mesma cesta/pedido), realizamos uma análise de frequência de pares de produtos em pedidos. Em outras palavras, contamos quantas vezes dois produtos diferentes apareceram juntos em um mesmo **InvoiceNo**. A implementação envolveu agrupar os itens de cada pedido e gerar todas as combinações de pares:

```
from itertools import combinations
from collections import Counter

pairs_counter = Counter()
# Agrupa descrições por pedido e conta combinações de 2 produtos
for invoice, items in sales_data.groupby('InvoiceNo')['Description']:
    unique_items = items.unique()
    for combo in combinations(unique_items, 2):
        pairs_counter[ tuple(sorted(combo)) ] += 1

# Top 5 pares mais frequentes
for combo, count in pairs_counter.most_common(5):
    print(combo, "->", count, "pedidos em comum")
```



```
('JUMBO BAG PINK POLKADOT', 'JUMBO BAG RED RETROSPOT') -> 825 pedidos em comum
('GREEN REGENCY TEACUP AND SAUCER', 'ROSES REGENCY TEACUP AND SAUCER ') -> 768 pedidos em comum
('JUMBO BAG RED RETROSPOT', 'JUMBO STORAGE BAG SUKI') -> 724 pedidos em comum
('JUMBO BAG RED RETROSPOT', 'JUMBO SHOPPER VINTAGE RED PAISLEY') -> 680 pedidos em comum
('LUNCH BAG BLACK SKULL.', 'LUNCH BAG RED RETROSPOT') -> 641 pedidos em comum
('ALARM CLOCK BAKELIKE GREEN', 'ALARM CLOCK BAKELIKE RED ') -> 640 pedidos em comum
('GREEN REGENCY TEACUP AND SAUCER', 'PINK REGENCY TEACUP AND SAUCER') -> 633 pedidos em comum
('LUNCH BAG PINK POLKADOT', 'LUNCH BAG RED RETROSPOT') -> 606 pedidos em comum
('PINK REGENCY TEACUP AND SAUCER', 'ROSES REGENCY TEACUP AND SAUCER ') -> 599 pedidos em comum
('JUMBO BAG BAROQUE BLACK WHITE', 'JUMBO BAG RED RETROSPOT') -> 585 pedidos em comum
```

Os resultados revelam padrões interessantes de **produtos frequentemente comprados juntos**. Por exemplo, os pares mais frequentes foram:

- **“JUMBO BAG PINK POLKADOT” + “JUMBO BAG RED RETROSPOT”** – aparecem juntos em **825 pedidos**.
- **“GREEN REGENCY TEACUP AND SAUCER” + “ROSES REGENCY TEACUP AND SAUCER”** – juntos em **768 pedidos**.
- **“JUMBO BAG RED RETROSPOT” + “JUMBO STORAGE BAG SUKI”** – juntos em **724 pedidos**.

Esses combos sugerem que clientes tendem a comprar **variações de um mesmo item** (ex.: bolsas jumbo de estampas diferentes, conjuntos de xícara de chá de estampas complementares, lancheiras de cores diferentes) na mesma compra. Isso representa oportunidades claras de **cross-selling**: recomendar ao cliente um item similar/complementar ao que ele já está comprando.

A empresa pode explorar isso criando **combos ou descontos na compra conjunta** desses itens correlacionados, aumentando o ticket médio e melhorando a experiência (já que o cliente possivelmente quer ambos os itens).

3.3 Relação entre Preço, Quantidade e Cancelamentos

Vamos analisar agora a relação entre **preço unitário e quantidade comprada**, bem como como esses fatores se relacionam com os cancelamentos.

Intuitivamente, espera-se que **itens mais baratos** sejam comprados em quantidades maiores (por serem acessíveis ou consumíveis), enquanto **itens caros** tendem a ser adquiridos em poucas unidades por pedido.

Para verificar isso, vamos calcular a correlação entre preço e quantidade e também vamos visualizar as distribuições:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Filtrar dados inválidos
valid_data = sales_data[
    (sales_data['UnitPrice'] > 0) &
    (sales_data['Quantity'] > 0)
].copy()
```





```

labels=['<1', '1-5', '5-10', '10-50', '50-100',
'>100'])
sns.boxplot(data=valid_data, x='price_bin', y='Quantity', showfliers=False)
plt.yscale('log')
plt.title('Distribuição de Quantidade por Faixa de Preço')
plt.xlabel('Faixa de Preço (USD)')
plt.ylabel('Quantidade (log)')

plt.tight_layout()
plt.show()

```



Em relação aos **cancelamentos/devoluções**, identificamos alguns padrões preocupantes:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

## 1. Preparação dos dados
# Criar coluna de identificação de devoluções
sales_data['is_return'] = sales_data['InvoiceNo'].isin(returns_data['InvoiceNo'])

# Separar dados
devolvidos = sales_data[sales_data['is_return']]
mantidos = sales_data[~sales_data['is_return']]
```

```
## 2. Análise estatística básica
print("\n=== Estatísticas Descritivas ===")
print("\nTodos os produtos:")
print(sales_data['UnitPrice'].describe())

print("\nProdutos devolvidos:")
print(devolvidos['UnitPrice'].describe())

print("\nProdutos mantidos:")
print(mantidos['UnitPrice'].describe())
```

```
## 3. Comparação de valores
comparacao = pd.DataFrame({
    'Todos': sales_data['UnitPrice'].describe(),
    'Devolvidos': devolvidos['UnitPrice'].describe(),
    'Mantidos': mantidos['UnitPrice'].describe()
})

# Calcular diferenças percentuais
comparacao['Dif_Devolvidos_vs_Mantidos'] = ((comparacao['Devolvidos'] -
comparacao['Mantidos']) / comparacao['Mantidos']) * 100
print("\nComparação detalhada:")
print(comparacao[['Devolvidos', 'Mantidos',
'Dif_Devolvidos_vs_Mantidos']].round(2))
```

```
## 4. Análise de outliers
# Definir outliers como preços acima do percentil 95
threshold = sales_data['UnitPrice'].quantile(0.95)
outliers_devolvidos = devolvidos[devolvidos['UnitPrice'] > threshold]

print(f"\nNúmero de outliers devolvidos (preço > {threshold:.2f}):
{len(outliers_devolvidos)}")
print("Top 5 produtos mais caros devolvidos:")
print(outliers_devolvidos.nlargest(5, 'UnitPrice')[['StockCode', 'Description',
'UnitPrice']])
```

```

## 5. Visualizações
plt.figure(figsize=(15, 6))

# Gráfico 1: Distribuição de preços
plt.subplot(1, 2, 1)
sns.boxplot(data=sales_data, x='is_return', y='UnitPrice', showfliers=False)
plt.yscale('log')
plt.title('Distribuição de Preços Unitários')
plt.xlabel('Status do Produto')
plt.ylabel('Preço Unitário (log)')
plt.xticks([0, 1], ['Mantidos', 'Devolvidos'])

# Gráfico 2: Proporção de devoluções por faixa de preço
plt.subplot(1, 2, 2)
sales_data['price_bin'] = pd.cut(sales_data['UnitPrice'],
                                bins=[0, 10, 50, 100, 200, 500, np.inf],
                                labels=['<10', '10-50', '50-100', '100-200', '200-500', '>500'])

return_rates = sales_data.groupby('price_bin')['is_return'].mean().reset_index()
sns.barplot(data=return_rates, x='price_bin', y='is_return')
plt.title('Taxa de Devolução por Faixa de Preço')
plt.xlabel('Faixa de Preço (USD)')
plt.ylabel('Taxa de Devolução')
plt.ylim(0, return_rates['is_return'].max() * 1.1)

plt.tight_layout()
plt.show()

```

```

## 6. Análise adicional - Produtos mais devolvidos
print("\nTop 10 produtos mais devolvidos:")
top_devolvidos = devolvidos['StockCode'].value_counts().head(10)
print(top_devolvidos)

# Verificar descrição dos produtos mais devolvidos
top_devolvidos_desc =
sales_data[sales_data['StockCode'].isin(top_devolvidos.index)][['StockCode',
'Description']].drop_duplicates()
print("\nDescrição dos produtos mais devolvidos:")
print(top_devolvidos_desc)

```

- Clientes **devolvem em maior proporção produtos de alto valor**: calculando o preço médio dos itens devolvidos versus não devolvidos, observamos que o **valor médio unitário dos itens devolvidos (~£46,20)** é muito superior ao dos itens mantidos (£3,87). Ou seja, produtos caros geram mais devoluções, talvez por não atenderem às expectativas ou por defeitos/dificuldade no transporte. No entanto, a mediana dos preços devolvidos (£2,55) é próxima à mediana geral, indicando que a maioria das devoluções ainda é de itens baratos (devoluções comuns), mas alguns itens muito caros puxam a média para cima. Esses outliers caros devolvidos sugerem casos específicos (ex.: um **item de £38970** aparece devolvido no dataset – possivelmente um equipamento ou móvel muito caro que foi cancelado).
- A distribuição de **quantidade** nos cancelamentos mostra que a maioria das devoluções são de poucas unidades (mediana de 2 unidades devolvidas), porém existem **casos de devolução em**

massa. O valor médio de quantidade devolvida por linha é ~45 unidades, novamente distorcido por eventos como devolução de lotes inteiros. Isso se deve a **ajustes de estoque e qualidade**, como evidenciado por descrições de devolução do tipo “Unsaleable, destroyed” (não vendável, destruído) ou “printing smudges” (problema de impressão). Esses registros indicam que milhares de unidades de certos itens foram retiradas de venda de uma vez. Por exemplo, o produto “*Paper Craft, Little Birdie*” já citado teve **100% das unidades vendidas devolvidas** (provavelmente todas essas unidades foram descartadas por problema de qualidade). Outro item, “*MEDIUM CERAMIC TOP STORAGE JAR*”, vendeu ~78 mil unidades mas teve ~74 mil devolvidas, indicando talvez uma quebra de estoque ou recall. Estes casos inflacionam a taxa de cancelamento e evidenciam a necessidade de controle de qualidade rigoroso antes de distribuir massivamente um produto.

- **Taxa de cancelamento:** No total, considerando todos os itens vendidos e devolvidos, aproximadamente **2% das linhas de item** registradas foram devoluções. Contudo, ao nível de pedidos, até **35% das faturas** têm alguma devolução associada (parcial ou total). Isso sugere que mais de 1 em cada 3 pedidos sofreu algum tipo de cancelamento ou ajuste. Provavelmente muitos desses cancelamentos são **parciais** (o cliente devolveu um item mas manteve outros do pedido). Ainda assim, é um percentual alto, implicando em custos logísticos e insatisfação do cliente que merecem atenção. Itens com maiores taxas de devolução devem ser investigados e possivelmente descontinuados ou melhorados.

Em resumo, a EDA nos forneceu importantes direcionamentos: identificamos a sazonalidade clara nas vendas, os produtos mais importantes em volume e valor (e alguns problemáticos), entendemos que itens baratos sustentam o volume enquanto itens premium impulsionam a receita, e que os cancelamentos estão concentrados em alguns produtos e possivelmente em clientes que compram grandes quantidades ou itens caros.

4. Segmentação de Clientes

Para aprofundar a análise, realizamos uma **segmentação da base de clientes**, com objetivo de identificar grupos de comportamento de compra semelhantes e possibilitar estratégias de marketing direcionadas. Utilizamos duas técnicas complementares: a análise **RFM (Recência, Frequência, Monetário)** e a **clusterização K-Means**.

A análise RFM é um método tradicional de marketing que categoriza clientes com base em:

- **Recência (R)**: quanto recente foi a última compra do cliente.
- **Frequência (F)**: com que frequência o cliente comprou no período.
- **Monetário (M)**: quanto dinheiro o cliente gastou no total.

Análise RFM

Vamos calcular os indicadores RFM para cada cliente identificado (CustomerID).

Vale notar que cerca de 25% das transações não continham CustomerID (clientes anônimos); esses não entram na segmentação.

É importante considerar apenas as compras (quantidade positiva) para RFM, ignorando as devoluções (as devoluções devem ser subtraídas do valor monetário gasto, para obter o gasto líquido de cada cliente).

Vamos definir a data de referência para Recência como *10/12/2011* (um dia após a última transação presente no dataset, 9/12/2011). A partir daí:

```
import datetime as dt

# Filtrando apenas compras (Quantity > 0) com CustomerID não nulo
customers_data = sales_data[sales_data['CustomerID'].notna()]

# Data de referência (um dia após a última compra no dataset)
ref_date = customers_data['InvoiceDate'].max() + dt.timedelta(days=1)

# Calculando R, F, M por cliente
rfm = customers_data.groupby('CustomerID').agg({
    'InvoiceDate': lambda x: (ref_date - x.max()).days,    # Recency: diferença em dias
    'InvoiceNo': 'nunique',                                # Frequency: número de pedidos únicos
    'TotalPrice': 'sum'                                     # Monetary: gasto total bruto
})
rfm.columns = ['Recency', 'Frequency', 'Monetary']

# Ajustando Monetary para gasto líquido (subtraindo devoluções do cliente)
# (somando todos os TotalPrice, onde devoluções têm valor negativo)
full_data = data[data['CustomerID'].notna()]
monetary_net = full_data.groupby('CustomerID')['TotalPrice'].sum()
rfm['Monetary'] = monetary_net

print(rfm.head())
```

Após esse cálculo, por exemplo, um cliente aleatório pode ter Recency = 30 dias (comprou pela última vez há 30 dias do fim do período), Frequency = 5 pedidos feitos e Monetary = £1000 gastos no total.

Para segmentar os clientes via RFM, atribuímos **escores de 1 a 4** para cada dimensão com base em quartis:

- **Recência:** clientes no quartil mais recente recebem R=4, enquanto os no quartil mais longo (mais tempo sem comprar) recebem R=1.
- **Frequência:** quartil de maior frequência recebe F=4 (compraram muitas vezes), quartil de menor frequência recebe F=1.
- **Monetário:** quartil de maior gasto total recebe M=4, quartil inferior recebe M=1.

```
# Atribuindo pontuações R, F, M por quartis
rfm['R_quartile'] = pd.qcut(rfm['Recency'], 4, labels=[4,3,2,1]) # R invertido (recência menor =>
valor maior)
rfm['F_quartile'] = pd.qcut(rfm['Frequency'], 4, labels=[1,2,3,4])
rfm['M_quartile'] = pd.qcut(rfm['Monetary'], 4, labels=[1,2,3,4])
# Concatenando scores para um score RFM combinado (ex: "414")
rfm['RFM_score'] = rfm['R_quartile'].astype(str) + rfm['F_quartile'].astype(str) +
rfm['M_quartile'].astype(str)
print(rfm[['Recency', 'Frequency', 'Monetary', 'RFM_score']].head(10))
```

Com os scores calculados, conseguimos **identificar segmentos-chave de clientes**. Por exemplo:

- **"Champions":** Clientes com RFM_score alto, por exemplo RFM = 444 (Top 25% em recência e frequência e monetário). Esses são os **melhores clientes**, que compraram recentemente, compram com frequência e gastam bastante. No dataset, há um grupo pequeno de clientes nessa categoria (poucas dezenas). São clientes VIP que devem ser priorizados com programas de fidelização e benefícios exclusivos.
- **"Clientes Frequentes":** Aqueles com F=4 (muitas compras) mas talvez Recência intermediária (R=2 ou 3, ou seja, não tão recente) e Monetário moderado. Possivelmente compradores recorrentes de baixo valor (compram muitas vezes itens baratos). Devem ser mantidos engajados, talvez com **programas de recompensa por frequência**.
- **"Grandes Gastadores Ocasionais":** por exemplo M=4, F=1 ou 2, R variando. São clientes que gastaram muito dinheiro em uma ou poucas compras. Um caso no dataset é o cliente **ID 12346**, que aparece com apenas 1 compra (Frequency=1) e gasto altíssimo (Monetary ~ £77 mil) – possivelmente um comprador por atacado que fez um grande pedido e depois parou. Se ele não comprou novamente (Recência alta, ruim), ele pode estar **adormecido**; valeria uma abordagem de reativação especialmente vantajosa, dado seu potencial de gasto.
- **"Recém-chegados":** R=4 (compraram muito recentemente), porém F=1 e M baixo. São **novos clientes** que fizeram sua primeira (e única) compra recentemente. Esse grupo é grande – muitos clientes compraram só uma vez. Convertê-los em recorrentes é vital: estratégias de **onboarding**, acompanhamento pós-compra e descontos na segunda compra podem ajudar a movê-los para segmentos de maior frequência.
- **"Em Risco/Prestes a Churnar":** R=1 (não compram há muito tempo) mas historicamente tinham F e M altos. Esses são clientes que **já foram valiosos** mas estão inativos há meses.

Devem ser alvos de campanhas de **win-back** (reconquista), com ofertas personalizadas para trazê-los de volta antes que churnem de vez.

- **"Clientes Perdidos"**: R=1, F=1, M=1 – aqueles que compraram pouco, há muito tempo, e não retornaram. Possivelmente não vale investir muito para reativá-los individualmente, mas entender por que não voltaram (experiência ruim? produto único?) pode trazer aprendizado. Campanhas genéricas de retargeting podem tentar recuperar alguns, mas o retorno tende a ser baixo.

Essa segmentação RFM fornece insumos para **ações de marketing direcionadas**: por exemplo, **Programa VIP** para “Champions”, **campanhas de upsell/cross-sell** para “Grandes Gastadores Ocasionais” incentivando mais frequência, **promoções de reativação** para “Em Risco”, e **educação e incentivos** para “Recém-chegados” aumentarem engajamento.

Clusterização K-Means (Agrupamento Automático)

Complementarmente, aplicamos o algoritmo de clusterização **K-Means** nos dados RFM para verificar se grupos semelhantes emergem de forma não supervisionada. Padronizamos as variáveis R, F, M (usando StandardScaler) e testamos uma segmentação em 4 clusters.

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

# Preparando dados RFM para clustering (normalização)
rfm_values = rfm[['Recency', 'Frequency', 'Monetary']].fillna(0).values
rfm_values_scaled = StandardScaler().fit_transform(rfm_values)

# Aplicando K-Means com 4 clusters
kmeans = KMeans(n_clusters=4, random_state=42)
rfm['Cluster'] = kmeans.fit_predict(rfm_values_scaled)

# Examinando características médias de cada cluster
print(rfm.groupby('Cluster')[['Recency', 'Frequency', 'Monetary']].mean())
```

	Recency	Frequency	Monetary
Cluster			
0	42.400000	4.133228	1503.336308
1	247.385330	1.552461	477.182034
2	7.666667	76.166667	182108.075000
3	10.135417	34.854167	20123.066979

A saída acima (centroides médios de cada cluster) mostrou diferenciações coerentes com a análise RFM manual:

- **Cluster 0**: Clientes com **Recência baixa (compraram muito recentemente)** porém **Frequência baixa** – essencialmente novos clientes (one-time recentes).
- **Cluster 1**: Clientes de **alta Recência (muito tempo sem comprar)**, **baixa Frequência** e **baixo gasto** – correspondem aos clientes inativos/perdidos.
- **Cluster 2**: Clientes com **baixa Recência (recentes)**, **alta Frequência** e **alto Monetário** – correspondendo aos “melhores clientes” identificados (um cluster de VIPs).
- **Cluster 3**: Clientes com **Recência média, Frequência e Monetário médios** – um grupo de clientes regulares, sem extremos.

Essa clusterização reforça os segmentos obtidos via RFM e ajuda a quantificar o tamanho de cada grupo. Por exemplo, o cluster de inativos (Cluster 1) era o maior em número de clientes, indicando que muitos clientes não voltaram a comprar; já o cluster 0 (VIPs) foi o menor, representando uma pequena parcela responsável por boa parte da receita.

Com os segmentos identificados, é possível personalizar estratégias de marketing:

- Para **VIPs (cluster 2)**: manter a satisfação alta, oferecer vantagens exclusivas (frete grátis, acesso antecipado a lançamentos, brindes), pois são clientes de altíssimo valor.
- Para **Regulares (cluster 3)**: programas de fidelidade para aumentar gradativamente o engajamento, talvez estimulando indicações ou maior frequência de compra.
- Para **Novos (cluster 0)**: nutrir relacionamento, enviar conteúdo de produto, pedir feedback da primeira compra e oferecer um cupom de desconto para a próxima compra, visando aumentar a frequência.
- Para **Inativos (cluster 1)**: campanhas de reativação, possivelmente via email marketing personalizado (“Sentimos sua falta, aqui um desconto especial se voltar!”) ou ofertas em produtos relacionados ao histórico deles. Se não responderem, removê-los gradualmente de campanhas pode ser eficiente em custo.

5. Insights Estratégicos e Recomendações

Com base na análise exploratória e segmentação, a seguir são apresentadas as principais **insights acionáveis** e recomendações de estratégias para a loja online:

- **Redução de Cancelamentos/Devoluções:** A taxa de cancelamento identificada é alta, impactando margem e satisfação. Recomenda-se investigar a fundo os produtos com maiores devoluções (como evidenciado, alguns itens foram completamente devolvidos). **Melhoria no controle de qualidade** é primordial – assegurar que produtos (especialmente os novos) sejam testados antes de vender em larga escala pode evitar devoluções em massa. Além disso, fornecer **descrições e imagens mais acuradas** no site pode alinhar expectativas e reduzir devoluções de produtos caros. Para itens frágeis ou de alto valor, melhorar a **embalagem e logística** diminui danos no transporte. Políticas de troca mais ágeis e suporte pró-ativo após a compra também podem converter potenciais devoluções em soluções (por exemplo, oferecer reparo ou desconto ao invés do retorno completo).
- **Aumento do Ticket Médio:** Os dados mostram várias oportunidades para elevar o valor médio por pedido. Uma estratégia é implementar **cross-sell e up-sell** no e-commerce: por exemplo, ao adicionar um “Jumbo Bag Red Retrosport” ao carrinho, sugerir o “Jumbo Bag Pink Polkadot” (que frequentemente é comprada junto) com um pequeno desconto no combo. Da mesma forma, oferecer kits (bundles) de produtos complementares, como o conjunto de xícaras “Green Regency” + “Roses Regency” juntos por um preço especial, pode incentivar clientes a levar ambos. Outra tática é estabelecer um **frete grátis acima de um valor mínimo** de compra, encorajando os clientes a incluírem mais itens no carrinho para atingir o patamar. Programas de **desconto progressivo** (ex: 5% off na compra acima de £50, 10% acima de £100) também podem elevar o gasto por pedido. Por fim, aproveitar a base de **clientes de alto valor** identificados para vendas de produtos premium: comunicar lançamentos de itens exclusivos ou versões upscale de produtos populares pode elevar o ticket nessas vendas.
- **Fidelização e Retenção de Clientes:** Dado que muitos clientes compraram apenas uma vez, é crucial melhorar a retenção. Implementar um **programa de fidelidade** pode ser eficaz – por exemplo, acumular pontos a cada compra que podem ser trocados por descontos ou brindes, estimulando a recorrência. Para os **“Champions” e clientes frequentes**, recompensas VIP (como cupons personalizados, atendimento prioritário, brindes surpresa em datas especiais) os farão se sentir valorizados e menos propensos a migrar para concorrentes. Já para os **clientes em risco/inativos**, montar campanhas de **reativação**: enviar e-mails lembrando produtos vistos ou relacionados às últimas compras deles, oferecer um **cupom de retorno** (“Volte e ganhe 15% off”) e destacar novidades pode reacender o interesse. Também é importante analisar feedbacks ou pesquisas de satisfação para entender porque não voltaram – por exemplo, se houve reclamação de atendimento ou qualidade, atuar diretamente nessas frentes. A **personalização de comunicação** de acordo com os segmentos (RFM/cluster) aumenta a relevância: clientes fiéis recebem novidades e ofertas exclusivas; clientes novos recebem tutorial de uso do produto comprado ou reviews para ganhar confiança; clientes sumidos recebem saudação e incentivo para voltar.
- **Otimização de Promoções e Marketing:** Os insights de sazonalidade indicam que campanhas promocionais devem ser calibradas com o calendário anual – por exemplo, intensificar

marketing antes do pico de novembro (Black Friday/Cyber Monday e Natal) para capitalizar o interesse, e planejar promoções de liquidação em períodos mais fracos (início do ano) para estimular demanda. Os produtos mais vendidos identificados podem ser usados como **carro-chefe em campanhas** (p.ex., destacar os mais populares na página inicial, ou usar o “Jumbo Bag” em anúncios para atrair tráfego, pois é um item de apelo amplo). Por outro lado, a empresa pode precisar **renovar o catálogo ou melhorar produtos** que tiveram desempenho fraco ou alto cancelamento, para não desperdiçar esforços de marketing neles. Com a segmentação de clientes, é possível fazer **campanhas segmentadas**: por exemplo, campanhas de email separadas – uma com produtos premium e novidades para clientes de alto valor, e outra oferecendo descontos mais agressivos em produtos de baixo custo para clientes sensíveis a preço que compraram pouco. Assim, o marketing torna-se mais eficiente, falando a língua de cada grupo de clientes.

Em conclusão, a análise de dados revelou **padrões valiosos** que orientam decisões: a empresa deve focar em manter e replicar o sucesso com itens populares, corrigir ou eliminar pontos de atrito (produtos problemáticos e alto índice de devolução), e **personalizar o relacionamento com o cliente** conforme seu perfil. Implementando essas recomendações – controle de qualidade, cross-sell estratégico, programas de fidelidade, campanhas segmentadas e melhoria contínua da experiência de compra – a loja online estará bem posicionada para **aumentar suas vendas e margens e construir uma base de clientes mais leais e satisfeitos**.