

DATA LAKE

PROJETO INTEGRADOR 3

TALITA BERBEL

talita.berbel@fatec.sp.gov.br

Fatec
Votorantim

CP
Centro
Paula Souza

AGENDA

- Definição
- Objetivos
- Recursos
 - Migração de Dados
 - Armazenamento e catalogação dados com segurança
 - Análise
 - Aprendizado de máquina
- Dataware house e Data Lake
- Benefícios

DEFINIÇÃO

Um **data lake** é um repositório centralizado que permite armazenar todos os seus dados estruturados e não estruturados em qualquer escala.

É utilizado para armazenar os dados como estão, sem precisar primeiro estruturá-los e executar diferentes tipos de análise, desde painéis e visualizações até processamento de big data, análise em tempo real e aprendizado de máquina para orientar melhores decisões.


OBJETIVOS

As organizações que implementam arquiteturas de dados modernas, incluindo data lakes, demonstraram vantagens mensuráveis em eficiência operacional e crescimento de receita.

Esses líderes usam análises avançadas, inteligência artificial e grandes modelos de linguagem em diversas fontes de dados, incluindo fluxos em tempo real, sensores de IoT, mídias sociais e dados de interação com o cliente.

OBJETIVOS

Essa estratégia de dados abrangente permite que as organizações tomem decisões baseadas em dados com mais rapidez, personalizem as experiências dos clientes, otimizem as operações por meio da manutenção preditiva e identifiquem novas oportunidades de receita antes dos concorrentes.



RECURSOS

As organizações utilizam data lakes e plataforma de análise, logo é necessário que considerarem vários recursos, incluindo:

- Migração de dados
- Armazenamento e catalogação dados com segurança
- Análise
- Aprendizado de máquina

MIGRAÇÃO DE DADOS

Os data lakes permitem a **importação** de um grande volume de dados em tempo real. Os dados são coletados de várias fontes e movidos para o data lake em seu formato original.

Esse processo permite escalar para dados de qualquer tamanho, economizando tempo na definição de estruturas de dados, esquemas e transformações.

ARMAZENAMENTO E CATALOGAÇÃO DADOS COM SEGURANÇA

Os data lakes permitem o armazenamento de dados relacionais, como bancos de dados operacionais e dados de aplicações de linha de negócios, e dados não relacionais, como aplicações móveis, dispositivos IoT e mídias sociais.

Eles também oferecem a capacidade de entender quais dados estão no data lake por meio de crawling, catalogação e indexação de dados. Por fim, os dados devem ser **protegidos** para garantir que seus ativos de dados estejam protegidos.

ANÁLISE

Os data lakes permitem que várias, como permitir que **cientistas de dados**, desenvolvedores de dados e analistas de negócios, acessem dados com sua escolha de ferramentas e frameworks analíticos.

Isso inclui frameworks de código aberto, como Apache Hadoop, Presto e Apache Spark, e ofertas comerciais de fornecedores de data warehouse e inteligência empresarial. Os data lakes permitem executar análises sem a necessidade de mover seus dados para um sistema de análise separado.

APRENDIZADOS DE MÁQUINA

O data lakes permitem que as organizações gerem diferentes tipos de insights, incluindo relatórios sobre dados históricos e **aprendizado de máquina**, onde os modelos são criados para prever resultados prováveis e sugerir uma série de ações prescritas para alcançar o resultado ideal.

DATAWARE HOUSE E DATA LAKE

Dependendo dos requisitos, uma organização típica exigirá um data warehouse e um data lake, pois atendem a diferentes necessidades e casos de uso.

Um **data warehouse** é um banco de dados otimizado para analisar dados relacionais provenientes de sistemas transacionais e aplicações de linha de negócios. A estrutura de dados e o esquema são definidos antecipadamente para otimizar consultas SQL rápidas, em que os resultados são normalmente usados para relatórios e análises operacionais. Os dados são limpos, enriquecidos e transformados para que possam atuar como a fonte única da verdade em que os usuários podem confiar.

DATAWARE HOUSE E DATA LAKE

Um data lake é diferente porque armazena dados relacionais de aplicações de linha de negócios e dados não relacionais de aplicativos móveis, dispositivos IoT e mídias sociais.

A estrutura dos dados ou esquema não é definida quando os dados são capturados. Isso significa que para armazenar todos os dados não se possui um design cuidadoso ou a necessidade de saber para quais perguntas serão de precisar de respostas no futuro. Diferentes tipos de análise em seus dados, como consultas SQL, análise de big data, pesquisa de texto completo, análise em tempo real e machine learning, podem ser usados para descobrir insights.

DATAWARE HOUSE E DATA LAKE

À medida que as organizações com data warehouses veem os benefícios dos data lakes, elas evoluem seu warehouse para incluir data lakes e habilitar diversos recursos de consulta, casos de uso de ciência de dados e recursos avançados para descobrir novos modelos de informações.

DATA LAKE

Dados



Desestruturado

Usuários



Cientista de dados
Engenharia de dados

Utilidade



Processamento de streaming
Aprendizado de Máquina
Análise em tempo real

DATA WAREHOUSE

Dados



Estruturado

Usuários



Analista de dados
Analista de Negócios
Business Intelligence

Utilidade



Processamento por lotes
BI e relatórios

Dados Brutos

Os Data Lakes contêm dados não estruturados, semi estruturados e estruturados com processamento mínimo. Ele pode ser usado para conter dados não convencionais, como logs e dados de sensores

Grandes

Os Data Lakes contêm vastas quantidades de dados na ordem de petabytes. Como os dados podem estar em qualquer forma ou tamanho, grandes quantidades de dados não estruturados podem ser armazenadas indefinidamente e podem ser transformadas quando em uso somente

Indefinidos

Os dados nos Data Lakes podem ser usados para uma ampla variedade de aplicações, como aprendizado de máquina, análise de fluxo e AI

Dados Refinados

Os Data Warehouses contêm dados altamente estruturados que são limpos, pré-processados e refinados. Este dados é armazenado para usos muito específicos, como BI.

Menores

Os Data Warehouses contêm menos dados na ordem de terabytes. Para manter a limpeza dos dados e a saúde do armazém, os dados devem ser processados antes da ingestão e é necessário uma purga periódica de dados

Relacional

Os Data Warehouses contêm dados históricos e relacionais, como sistemas de transações, operações etc.

BENEFÍCIOS

Os data lakes oferecem uma série de benefícios, incluindo:

- **Escalabilidade:** eles podem ser dimensionados para atender às necessidades das cargas de trabalho mais exigentes. Eles podem lidar com petabytes de dados e milhares de usuários simultâneos.
- **Desempenho:** são otimizados para desempenho e podem fornecer insights de dados de forma rápida e eficiente.
- **Flexibilidade:** podem armazenar dados em qualquer formato.
- **Custo-benefício:** são uma maneira econômica de armazenar e gerenciar grandes conjuntos de dados.

BENEFÍCIOS

Os data lakes oferecem uma série de benefícios, incluindo:

- **Escalabilidade:** eles podem ser dimensionados para atender às necessidades das cargas de trabalho mais exigentes. Eles podem lidar com petabytes de dados e milhares de usuários simultâneos.
- **Desempenho:** são otimizados para desempenho e podem fornecer insights de dados de forma rápida e eficiente.
- **Flexibilidade:** podem armazenar dados em qualquer formato.
- **Custo-benefício:** são uma maneira econômica de armazenar e gerenciar grandes conjuntos de dados.

REFERÊNCIAS

AMAZON WEB SERVICES. O que é um data lake? Disponível em: <https://aws.amazon.com/pt/what-is/data-lake/>. Acesso em: 29 maio 2025.

USCLOUD. Data Lake vs. Data Warehouse: What's the Difference? Disponível em: <https://www.uscloud.com/data-lake-vs-data-warehouse/>. Acesso em: 29 maio 2025.